RAPPORT D'ANALYSE DES DONNÉES

Test technique Data Scientist
Profil orienté Data Engineering

Nostrum Care

Candidat : Gildas EDENAKPO

Date du rendu : 22 octobre 2026

Contexte et données

Le fichier Excel Data contient quatre feuilles :

Feuille	Contenu
Contrats	Informations sur les contrats des adhérents
Remboursements	Remboursements effectués aux adhérents
Product	Liste des produits
Stripe	Historique des paiements

Le rapport répond successivement aux questions des parties Data Quality, Statistiques, Data Science et Data Engineering.

Résumé exécutif

L'analyse porte sur les données de contrats, de paiements Stripe, de remboursements et de produits. Les traitements et interprétations présentés dans ce rapport reprennent les éléments produits dans les quatre notebooks du dossier.

Élément	Résultat issu des notebooks
Contrats utilisés	12 216
Clients	12 027
Transactions Stripe	166 366
Demandes de remboursement	53 221
Produits	58

Les analyses montrent que les anomalies de clés, de dates et de structure peuvent modifier sensiblement les indicateurs financiers. Une jointure naïve aurait notamment compté 121 876 € d'encaissements en double. Après nettoyage, les statistiques décrivent un ralentissement des clients gagnés, une progression du taux de perte et une hausse des échecs de prélèvement.

1. Périmètre et démarche

Le fichier Excel contient quatre feuilles : Contrats, Remboursements, Product et Stripe. La date du 19/10/2026 est retenue comme date d'extraction, car elle correspond à la dernière clôture cohérente d'un contrat fermé et à la dernière décision de remboursement observée.

La démarche suit les étapes suivantes :

- chargement des données brutes ;
- profilage des tables ;
- recensement des anomalies ;
- analyse chiffrée et graphique ;
- nettoyage et export des tables propres.

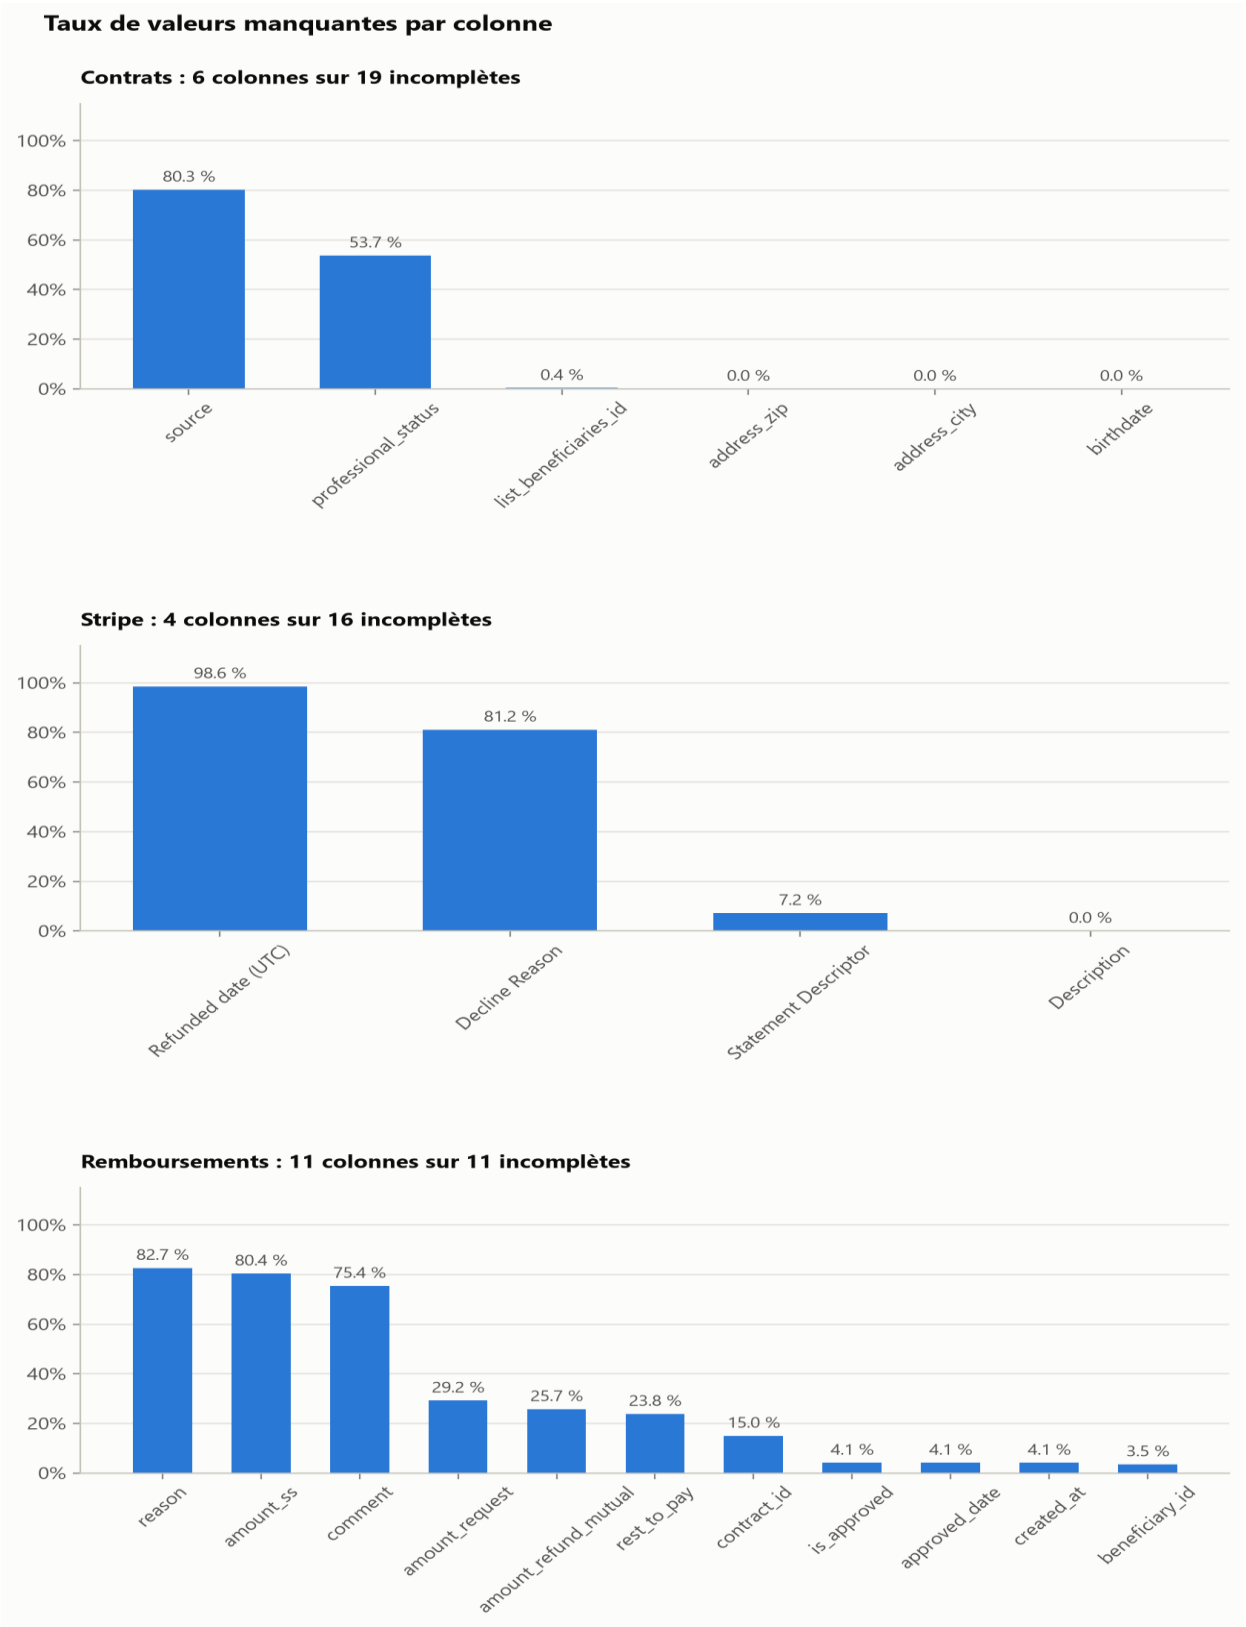
Le principe de nettoyage est de ne supprimer que les lignes inexploitées ou non réparables. Les anomalies ambiguës sont conservées et signalées par des indicateurs afin de ne pas perdre l'information.

Partie 1 : Data Quality

Question 1 : Récensement des anomalies dans les relations entre Contrats, Stripe et Remboursements.

Table	Lignes brutes	Colonnes	Lignes exploitées
Contrats	12 484	19	12 216
Stripe	166 373	16	166 366
Remboursements	55 522	11	53 221
Product	58	5	58

Figure 1 : Valeurs manquantes par colonne



Interprétation

La figure permet d'identifier les colonnes les plus incomplètes et de prioriser les contrôles de complétude avant les jointures.

Seules les tables Contrats et Product disposent d'une clé apparente. Stripe et Remboursements ne possèdent pas d'identifiant de transaction ou de demande fourni par la source.

Question 2 : Analyse chiffrée des anomalies

- Dans Stripe, les dates sont stockées sous forme de numéros de série Excel et les montants sous forme de texte avec une virgule décimale.
- Dans Remboursements, trois colonnes de montants contiennent des chaînes non numériques, des UUID ou des motifs de refus.
- Dans Contrats, created_at est un texte avec fuseau horaire et address_zip est numérique, ce qui peut faire perdre les zéros initiaux.
- Les dates et montants ont été convertis avant les contrôles relationnels.

Code	Anomalie	Volume	Taux	Traitement
S1	Dates Stripe en numéro de série Excel	166 373	100,0 %	Conversion en datetime
S2	Montants Stripe en texte	166 373	100,0 %	Conversion numérique
R5	Montants de remboursement non numériques	742	1,3 %	Valeurs non convertibles mises à vide
C6	Codes postaux incomplets ou invalides	672	5,4 %	Conversion en texte et contrôle

2.3 Structure de Remboursements

La table contient des lignes entièrement vides et des lignes fragmentées, sans date ni statut, avec des valeurs décalées entre les colonnes. Cette structure est interprétée comme un export corrompu non réparable de manière fiable.

Anomalie	Volume	Part
Lignes entièrement vides	1 470	2,6 %
Lignes fragmentées	831	1,5 %
Total inexploitables	2 301	4,1 %

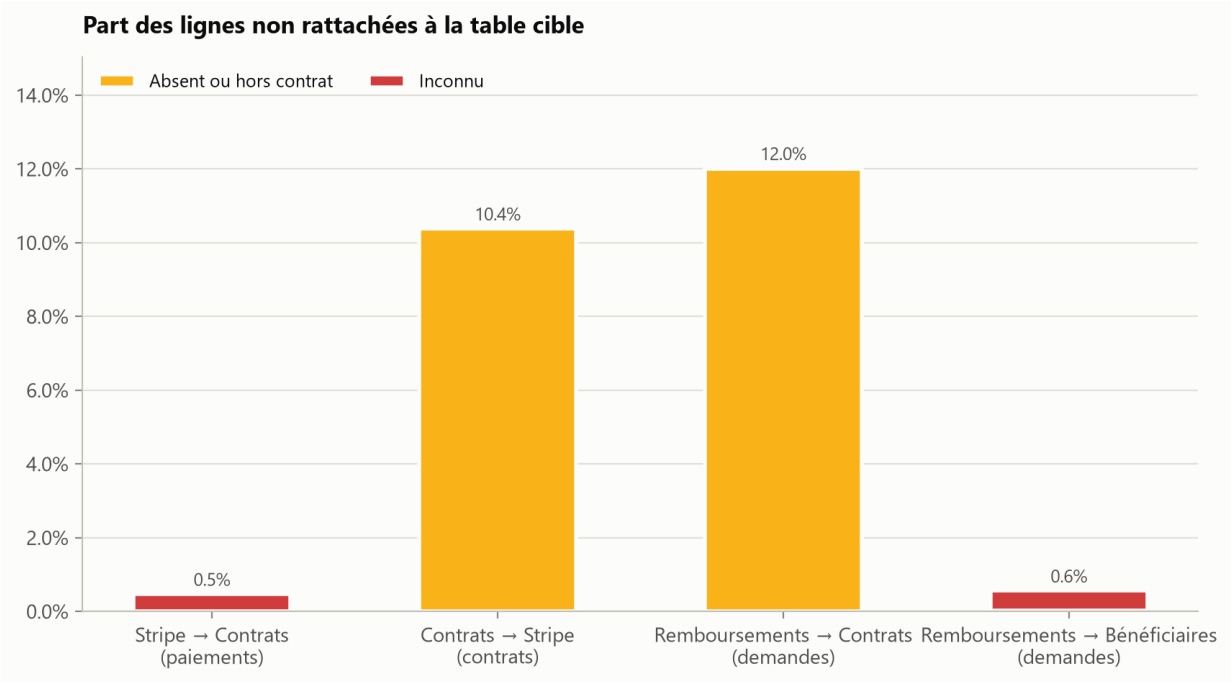
Les 53 221 demandes restantes sont utilisées dans les analyses. Les doublons exacts et les dates aberrantes observés dans les lignes brutes disparaissent après retrait des lignes inexploitables.

2.4 Clés et intégrité référentielle

248 contrats apparaissent sur plusieurs lignes, soit 268 lignes excédentaires. Les variables beneficiary_id et created_at varient systématiquement dans les groupes concernés, tandis que les attributs principaux restent généralement identiques. Cela correspond à une double saisie du même souscripteur.

Contrôle	Résultat
Contrats dupliqués	248 contrats / 516 lignes
Lignes Stripe ajoutées par jointure naïve	+3 328
Encaissements doublés	121 876 €
Lignes Remboursements ajoutées	+425
Remboursements doublés	13 881 €

Figure 2 : Couverture référentielle entre les tables



Interprétation

La figure met en évidence les paiements et remboursements qui ne peuvent pas être rattachés de façon certaine aux contrats ou aux bénéficiaires.

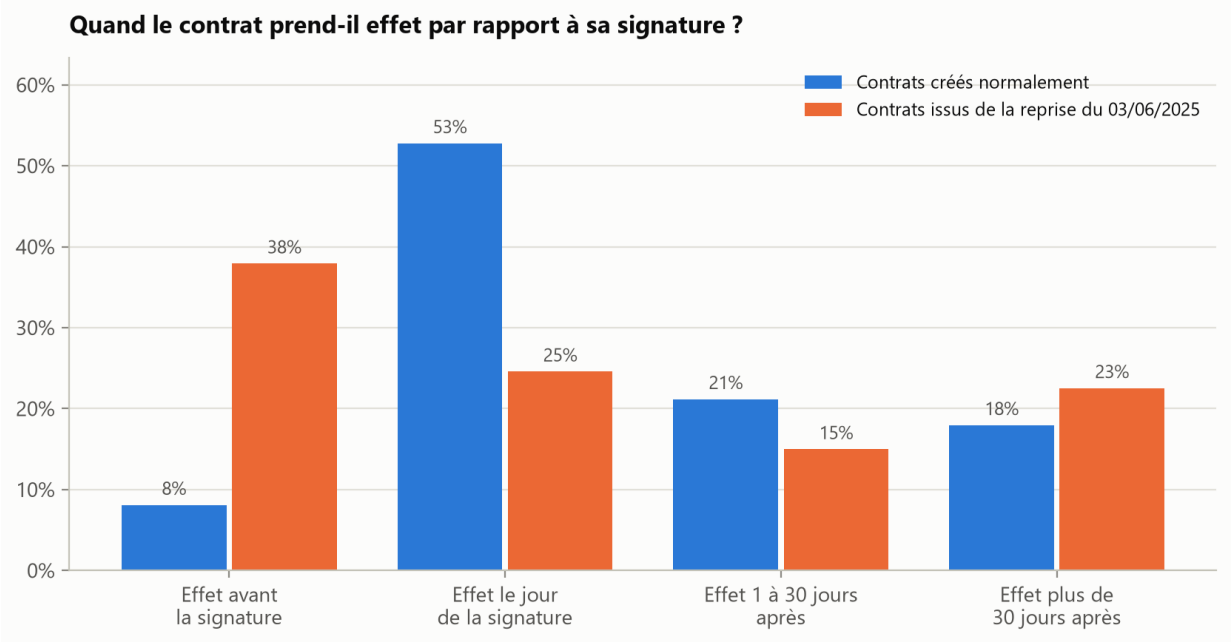
793 paiements Stripe, correspondant à 74 contrats, citent un contrat absent de Contrats. Ils représentent 43 796 € et sont signalés puis exclus des analyses croisées.

Anomalie Remboursements	Volume	Taux
Contrat absent	6 391	12,0 %
Contrat inconnu	8	0,0 %
Bénéficiaire inconnu	286	0,5 %
Bénéficiaire connu mais hors contrat	16	0,0 %

2.5 Cohérence temporelle

Les dates des contrats sont peu fiables de manière uniforme. La date de clôture est renseignée pour les 5 312 contrats en cours. La date de création correspond à la date de reprise du 03/06/2025 pour 6 869 contrats, soit 56,2 %. Deux dates de signature par défaut concernent 2 924 contrats, soit 23,9 % des contrats uniques.

Figure 3 : Écart entre date d'effet et date de signature

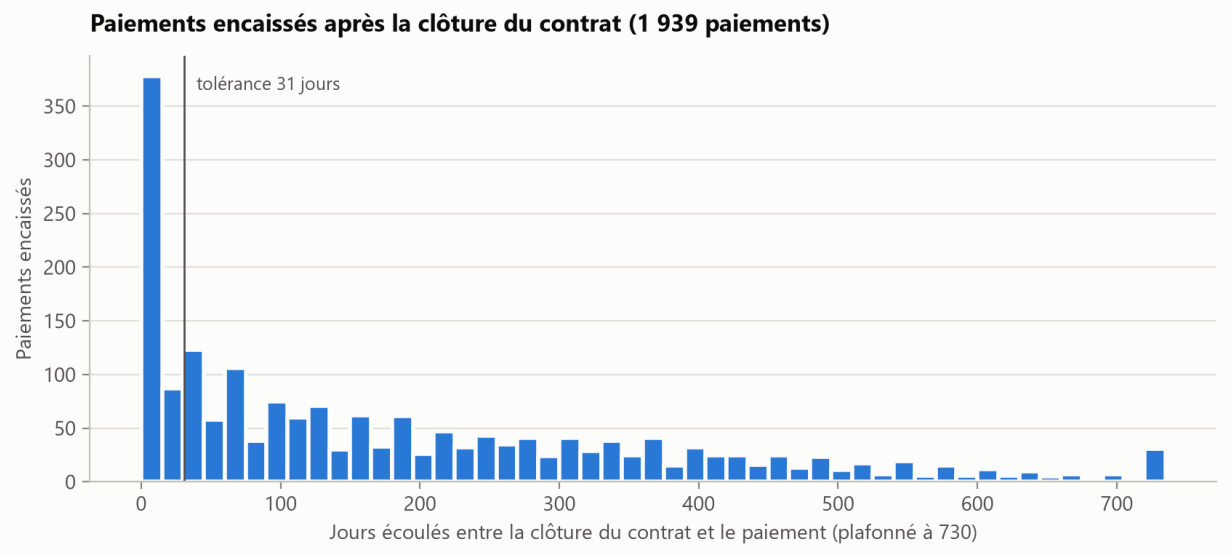


Interprétation

La concentration des écarts confirme que les dates de signature et de début ne peuvent pas être utilisées sans règles de fiabilisation.

Concernant Stripe, 1 446 paiements ont lieu plus de 31 jours après la clôture, pour un montant de 95 110 €. La distribution s'étale sur deux ans ; il peut s'agir de prélèvements non arrêtés ou de dates de clôture erronées.

Figure 4 : Paiements encaissés après clôture



Interprétation

La présence de paiements longtemps après la clôture constitue un signal à contrôler avec les équipes finance et gestion.

456 remboursements approuvés, représentant 17 366 €, concernent 119 contrats qui n'ont jamais enregistré de cotisation encaissée. Ce point constitue un signal de risque côté contrôle à l'adhésion ou fraude.

Question 3 : Nettoyage des tables avant les statistiques

- conversion des dates Excel et des montants textuels ;
- suppression des lignes vides et fragmentées ;
- dédoublonnage des contrats et création d'une ligne canonique ;
- dépliage de la liste des bénéficiaires dans une table pont ;
- normalisation des villes, statuts et canaux ;
- création d'identifiants techniques pour les tables sans clé ;
- conservation des anomalies ambiguës sous forme de flags.

L'analyse révèle que, malgré leur exploitabilité individuelle, les tables présentent des anomalies de cohérence susceptibles de fausser les indicateurs : doublons de contrats entraînant un double comptage de 121 876 €, 793 paiements associés à des contrats inconnus, 1 446 paiements tardifs représentant 95 110 € et 456 remboursements concernant des contrats n'ayant jamais cotisé. La fiabilité temporelle est également fragilisée par l'écrasement de la date de création de 56 % des contrats, des erreurs sur 24 % des dates de signature et la présence de dates de clôture sur des contrats encore en cours. Le nettoyage a privilégié la conservation de l'information, avec la suppression de 2,1 % des contrats et de 4,1 % des remboursements, les autres anomalies étant corrigées ou signalées. Pour la suite, chaque client est identifié par son user_id, chaque contrat n'est compté qu'une fois et la date de souscription est déterminée à partir de la date de création fiable ou, à défaut, de la date de signature valide. Enfin, les contrats annulés avant leur date d'effet sont exclus du calcul des clients gagnés et perdus, afin de produire des indicateurs plus cohérents et représentatifs de l'activité réelle.

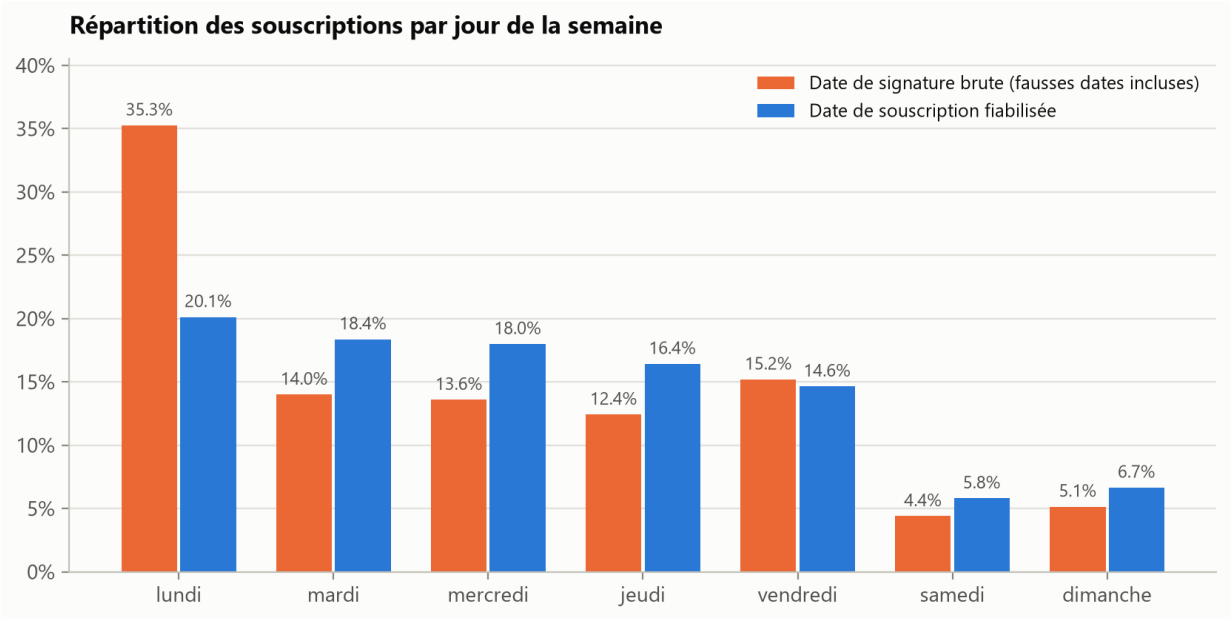
Partie 2 : Statistiques

Question 1 : Jours de souscription

La date de souscription est choisie selon une hiérarchie : created_at est utilisée lorsqu'elle est fiable ; sinon la signature est retenue si elle n'est pas une date par défaut. 9 322 contrats sont analysés, du 06/08/2024 au 19/10/2026.

Jour	Part
Lundi	20,1 %
Mardi	18,4 %
Mercredi	18,0 %
Samedi + dimanche	12,5 %

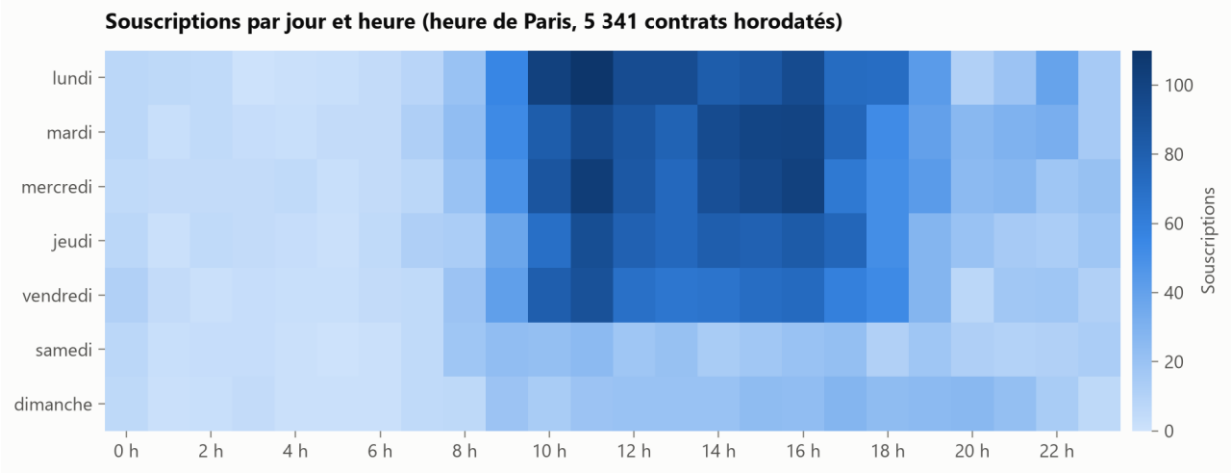
Figure 5 : Répartition des souscriptions par jour



Interprétation

Le lundi arrive en tête avec 20,1 %, tandis que les données brutes surestiment artificiellement ce jour à cause des dates de signature par défaut.

Figure 6 : Souscriptions par jour et par heure



Interprétation

Le pic est observé à 11 h ; 74 % des souscriptions horodatées ont lieu entre 9 h et 18 h et 20 % après 18 h.

Le lundi est le jour de souscription le plus fréquent, mais de peu devant le mardi et le mercredi. Sans correction, le lundi aurait atteint 35 % à cause d'une date par défaut. Le pic horaire est à 11 h ; 74 % des souscriptions horodatées surviennent entre 9 h et 18 h et 20 % après 18 h.

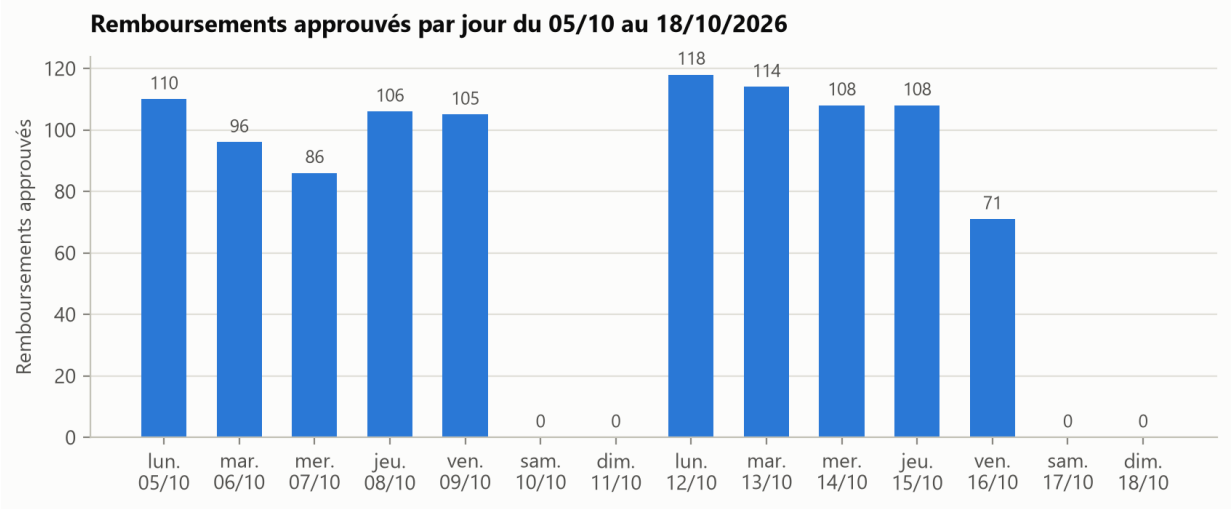
L'interprétation métier est de concentrer les publicités et relances du dimanche soir au mardi, et de renforcer le service client le lundi et le mardi.

Question 2 : Remboursements rapides entre le 05/10/2026 et le 18/10/2026

Entre le 05/10/2026 et le 18/10/2026, 1 022 demandes sont approuvées, dont 1 004 avec un montant positif. Le délai mesurable est de zéro jour pour toutes les demandes, car created_at et approved_date coïncident.

Indicateur	Résultat
Demandes approuvées	1 022
Demandes avec montant positif	1 004
Bénéficiaires distincts	741
Adhérents distincts	716
Délai mesurable	0 jour

Figure 7 : Remboursements approuvés du 5 au 18 octobre 2026



Interprétation

La figure présente le volume quotidien des remboursements approuvés sur la fenêtre demandée.

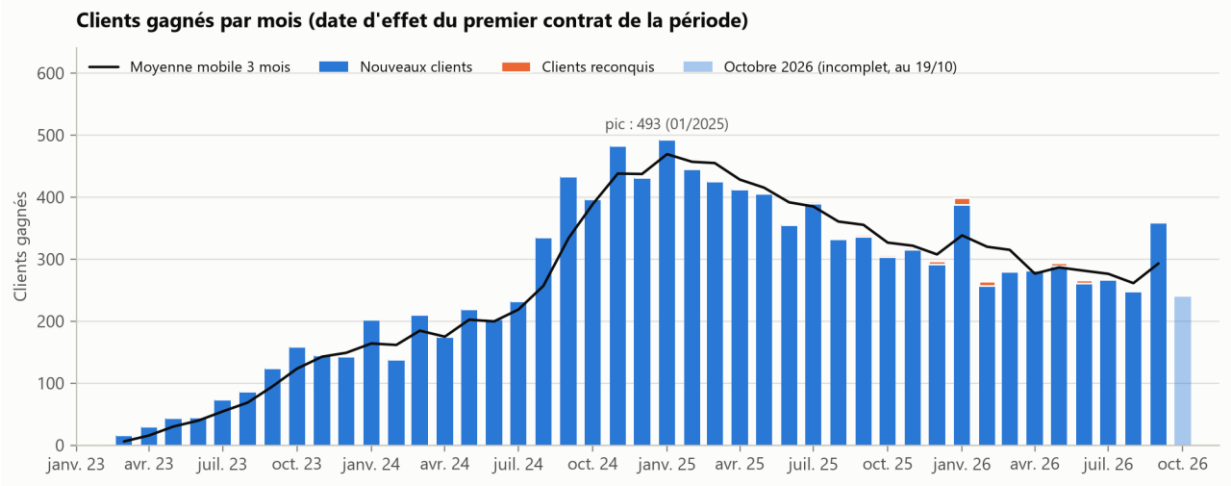
Rappelons que le vrai délai d'attente de l'adhérent n'est pas mesurable avec les données disponibles : created_at correspond vraisemblablement au traitement gestionnaire. Une lecture alternative depuis la date d'effet du contrat donne 12 bénéficiaires, 15 remboursements et 475 €.

Question 3 : Évolution mensuelle des clients gagnés

Les contrats successifs ou simultanés d'un même user_id sont regroupés en périodes d'activité. Les contrats qui se chevauchent ou se suivent à moins de 31 jours sont fusionnés. Les contrats annulés avant effet et les contrats à effet futur sont exclus.

Indicateur	Résultat
Clients	11 706
Périodes d'activité	11 771
Reconquêtes	65
Clients actifs au 19/10/2026	5 278
Pic mensuel	493 en janvier 2025

Figure 8 : Évolution mensuelle des clients gagnés



Interprétation

Le pic atteint 493 clients gagnés en janvier 2025, puis la moyenne mensuelle ralentit jusqu'à 296 entre janvier et septembre 2026.

La moyenne mensuelle est de 289 clients gagnés en 2024, 423 au premier semestre 2025, 332 au second semestre 2025 et 296 entre janvier et septembre 2026. Le notebook interprète cette évolution comme une croissance jusqu'à janvier 2025, puis un ralentissement, avec une saisonnalité liée aux changements de complémentaire au 1er janvier. Les sources d'acquisition ne permettent pas d'expliquer complètement le ralentissement car 46 % des contrats de 2026 n'ont pas de source renseignée.

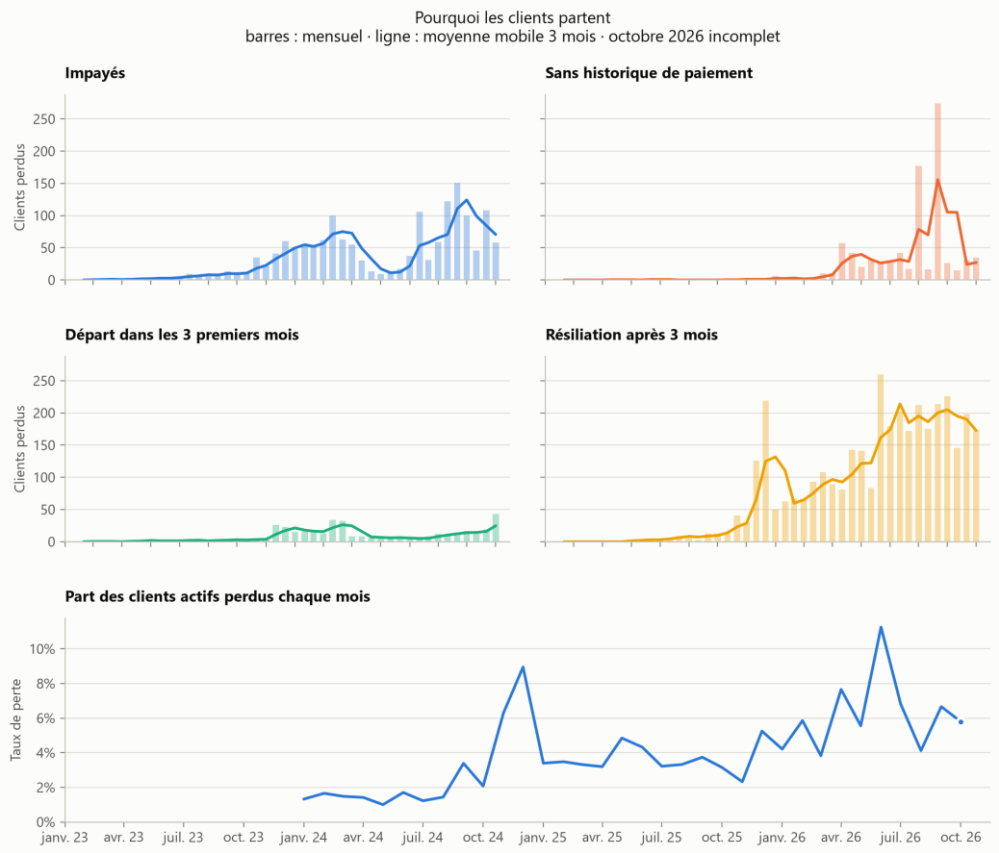
Question 4 : Évolution mensuelle des clients perdus

Un client est perdu à la fin d'une période d'activité lorsque son dernier contrat actif est fermé. Un changement de formule ne constitue pas une perte.

Motif probable	Nombre
Résiliation après 3 mois	3 640
Impayés	1 576
Sans historique de paiement	880
Départ dans les 3 premiers mois	397

Indicateur	Résultat
Pertes	6 493
Ancienneté médiane à la perte	9,7 mois
Taux de perte moyen 2024	2,7 %
Taux de perte moyen 2025	3,6 %
Taux de perte moyen 2026	6,2 %

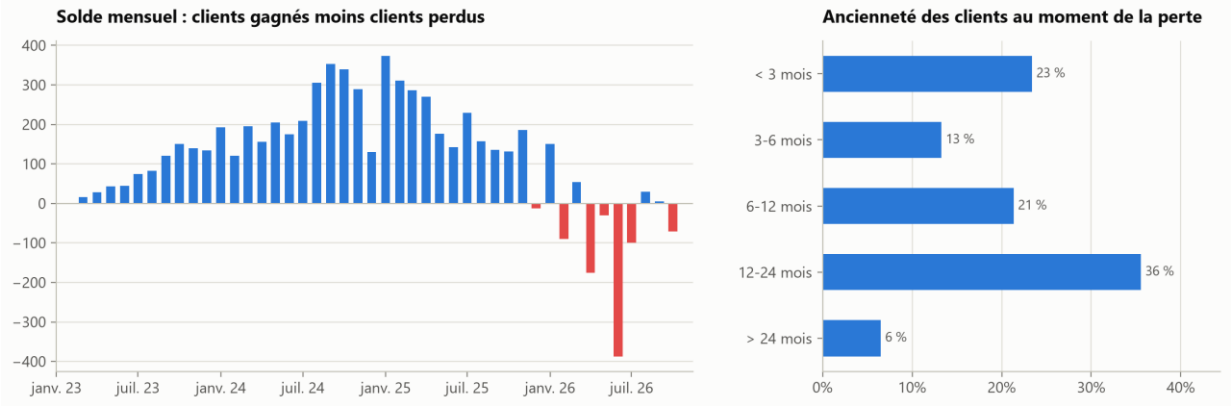
Figure 9 : Évolution mensuelle des clients perdus



Interprétation

Le taux de perte mensuel moyen progresse de 2,7 % en 2024 à 6,2 % en 2026 ; les impayés constituent un motif important.

Figure 10 : Solde mensuel et ancienneté à la perte



Interprétation

23 % des pertes surviennent avant trois mois et 36 % entre 12 et 24 mois ; les clôtures groupées doivent être distinguées des pertes opérationnelles.

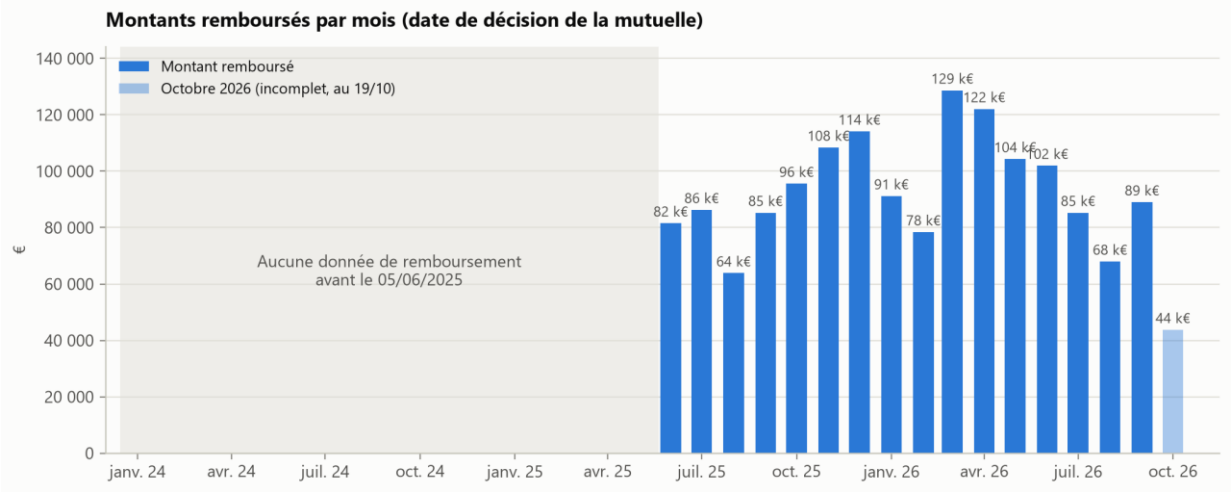
23 % des pertes interviennent avant trois mois et 36 % entre 12 et 24 mois. Les impayés représentent une part importante des départs et sont en hausse. Les clôtures groupées doivent cependant être distinguées des départs opérationnels, notamment lorsqu'elles sont liées à une purge de contrats hérités de la reprise.

Question 5 : Évolution mensuelle des montants remboursés depuis 2024

Les remboursements exploitables commencent le 05/06/2025. Le total remboursé est de 1 547 862 €, la moyenne mensuelle des mois complets de 94 007 €, le montant médian de 26,64 € et le montant moyen de 37,73 €.

Indicateur	Résultat
Premier remboursement	05/06/2025
Dernier remboursement	19/10/2026
Total remboursé	1 547 862 €
Moyenne mensuelle	94 007 €
Minimum mensuel complet	63 840 € en août 2025
Maximum mensuel complet	128 699 € en mars 2026

Figure 11 : Évolution mensuelle des montants remboursés



Interprétation

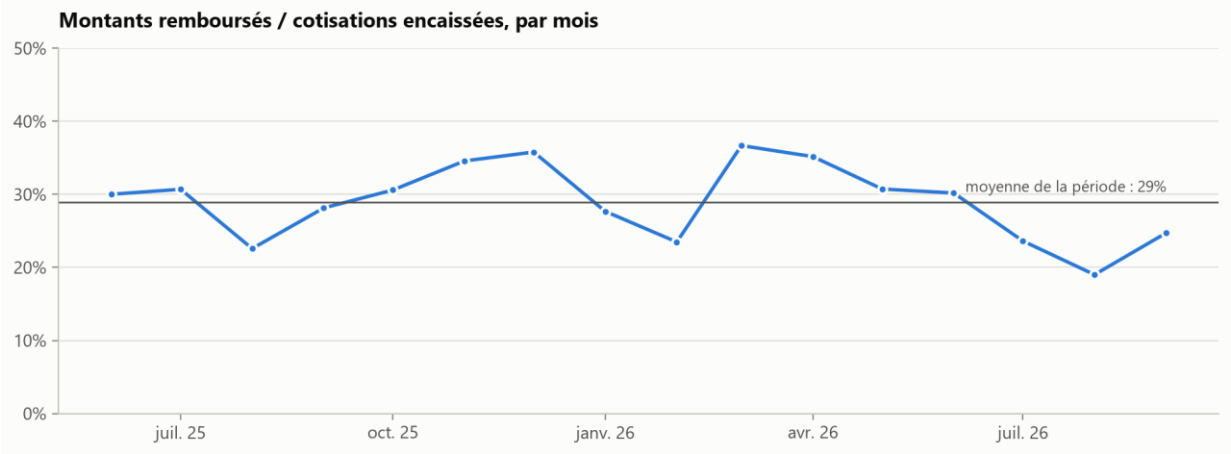
Les montants exploitables commencent en juin 2025 ; le maximum des mois complets est observé en mars 2026 avec 128 699 €.

Question 6 : Deux statistiques importantes pour le business

S/P apparent

Le S/P apparent est calculé entre juin 2025 et septembre 2026, seule période où les données de remboursements et de cotisations sont comparables. Il atteint 28,9 %, avec un minimum de 19,0 % en août 2026 et un maximum de 36,7 % en mars 2026.

Figure 12 : S/P apparent mensuel



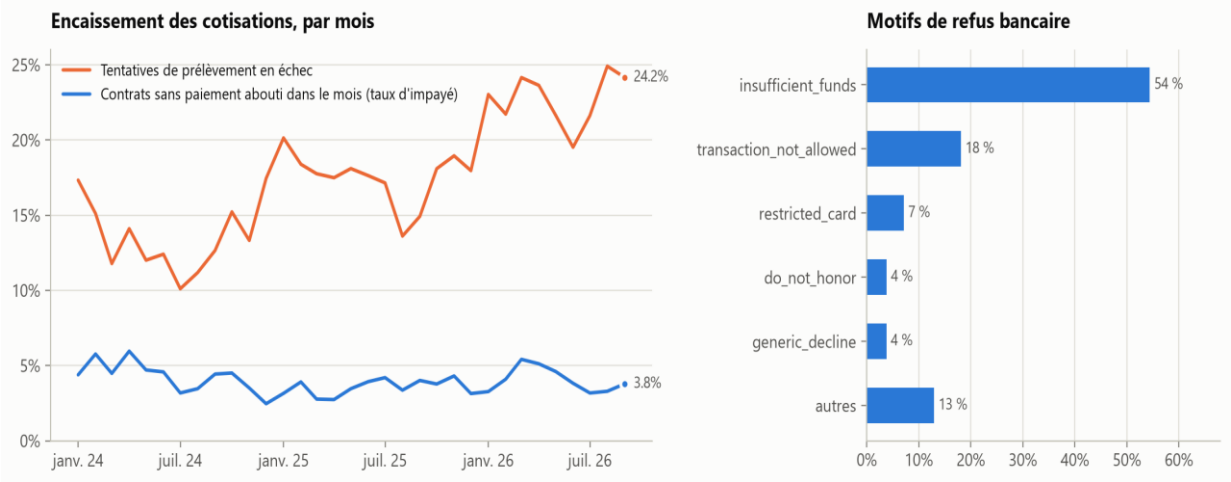
Interprétation

Le S/P apparent atteint 28,9 % sur juin 2025-septembre 2026, avec un minimum de 19,0 % et un maximum de 36,7 %.

Échecs de prélèvement et impayés

La part des tentatives en échec passe de 13,6 % en 2024 à 17,5 % en 2025 et 22,7 % en 2026. Le taux d'impayé reste autour de 4 %, car le système réessaie les prélèvements. En 2026, les cotisations non recouvrées dans le mois représentent environ 16 145 €, soit 4,7 % des cotisations encaissées.

Figure 13 : Échecs de prélèvement et impayés



Interprétation

Les tentatives en échec progressent de 13,6 % en 2024 à 22,7 % en 2026, tandis que le taux d'impayé reste proche de 4 % grâce aux nouvelles tentatives.

Les actions proposées dans sont donc : prévenir le client avant l'échéance, relancer après les dates de versement des salaires et allocations, et proposer le prélèvement SEPA.

L’analyse met en évidence une dynamique commerciale contrastée : les souscriptions sont principalement enregistrées le lundi (20,1 %), devant le mardi (18,4 %), tandis que le pic apparent de 35 % le lundi s’explique par un artefact de date par défaut. Entre le 5 et le 18 octobre 2026, 741 bénéficiaires, correspondant à 716 adhérents, ont été remboursés en moins de sept jours, avec un délai mesuré systématiquement égal à zéro jour, ce qui appelle à vérifier la fiabilité de cet indicateur. Après un pic de 493 clients gagnés en janvier 2025, les recrutements ralentissent d’environ 30 % en 2026, pour atteindre 296 clients gagnés par mois. Parallèlement, le taux de perte progresse de 2,7 % en 2024 à 6,2 % en 2026, et le solde atteint −614 clients en 2026, dont 400 départs liés à une purge de contrats hérités de la reprise. Les montants remboursés, indisponibles avant le 5 juin 2025, s’établissent ensuite autour de 94 k€ par mois, avec un creux en août et des pics en fin d’année ainsi qu’en mars-avril. Enfin, si le S/P apparent s’élève à 29 %, les échecs de prélèvement atteignent 23 % des tentatives, malgré un taux d’impayés contenu à 4 %. La lecture business est claire : le ralentissement des recrutements, l’augmentation des pertes et les difficultés de prélèvement imposent de piloter la croissance en tenant compte de la qualité du portefeuille. Le suivi mensuel doit distinguer les nouvelles acquisitions, les reconquêtes, les départs effectifs et les effets de la reprise des données, tout en renforçant la fiabilité des sources d’acquisition, la prévention des impayés et le suivi des premiers mois de couverture.

Partie 3 : Data Science

Proposition d'un clustering de la base clients

L'objectif est de mieux comprendre les profils clients, leur valeur, leur consommation et leur risque de départ. Un clustering est choisi afin de faire émerger des combinaisons de comportements.

La fenêtre d'observation va du 05/06/2025 au 19/10/2026. La population finale comprend 8 470 clients couverts au moins un mois, appartenant à la gamme Vita et disposant d'un historique de paiement Stripe.

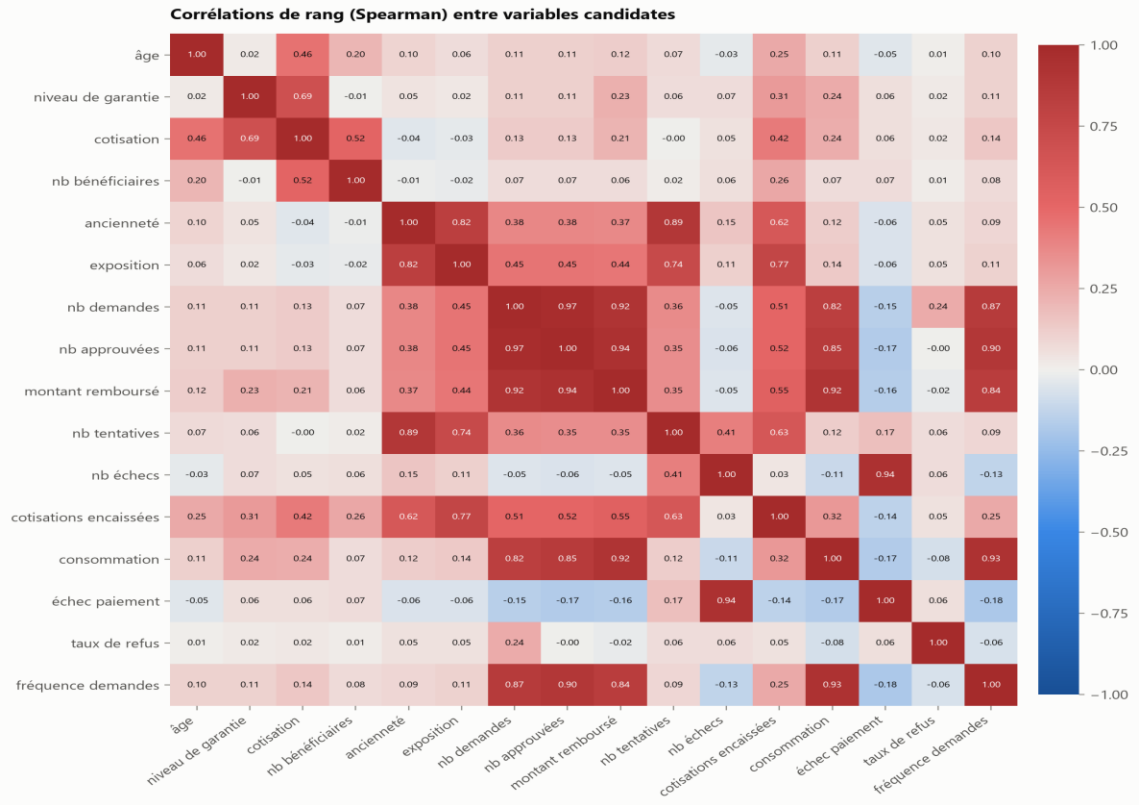
4.2 Variables et préparation

- âge ;
- niveau de garantie ;
- nombre de bénéficiaires ;
- ancienneté ;
- consommation mensuelle ;
- taux d'échec de paiement.

Les corrélations de Spearman servent à éliminer les variables redondantes. Les variables consommation mensuelle et nombre de bénéficiaires sont transformées par log(1+x), puis les variables sont standardisées. Les critères utilisés pour choisir k sont l'inertie et la silhouette.

L'inertie suggère quatre groupes tandis que la silhouette favorise trois groupes. Le choix final est de quatre segments, car il fournit un compromis entre stabilité élevée et interprétabilité métier.

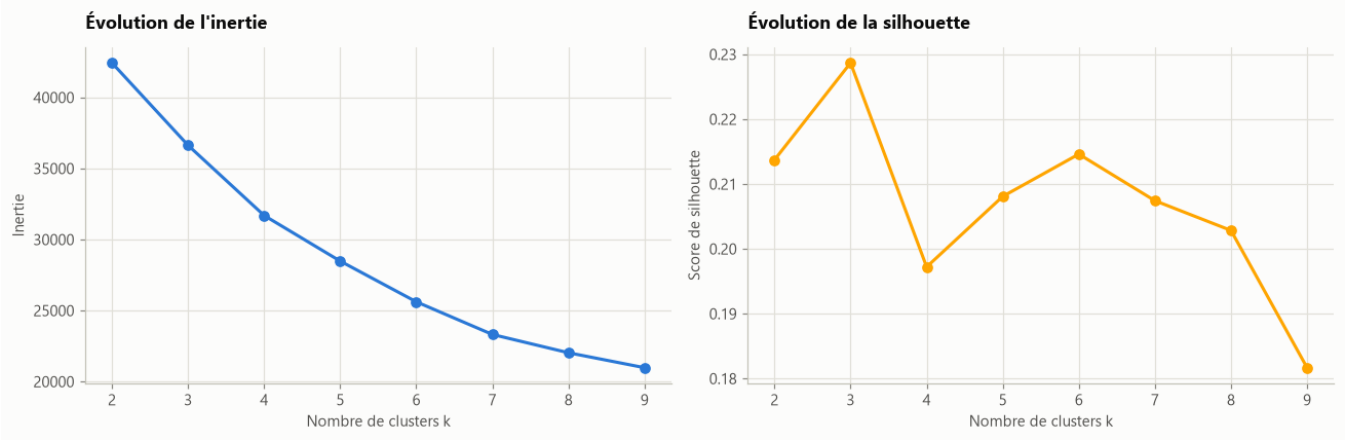
Figure 14 : Corrélations entre variables candidates



Interprétation

Les corrélations de Spearman servent à retirer les variables redondantes avant le clustering.

Figure 15 : Choix du nombre de groupes



Interprétation

L'inertie favorise quatre groupes tandis que la silhouette en favorise trois ; quatre segments sont retenus pour leur stabilité et leur interprétabilité.

Figure 16 : Projection des segments dans le plan d'ACP



Interprétation

Les deux premiers axes expliquent 45 % de la variance et permettent de visualiser la séparation des segments.

4.3 Résultats et interprétation business

Segment	Clients	Cotisations	Remboursements	S/P	Partis
Bien couverts et consommateurs	32 %	43 %	56 %	38 %	36 %
Familles nombreuses	5 %	13 %	10 %	22 %	45 %
Faible consommation	50 %	39 %	32 %	24 %	37 %
Risque de paiement	13 %	5 %	3 %	15 %	72 %
Ensemble	100 %	100 %	100 %	29 %	41 %

Bien couverts et consommateurs

Ce segment représente 32 % des clients, 43 % des cotisations et 56 % des remboursements. Il constitue le cœur de la valeur mais présente le S/P le plus élevé. Le notebook recommande de le fidéliser et d'éviter les hausses tarifaires brutales.

Familles nombreuses

Ce segment représente 5 % des clients mais 13 % des cotisations. Avec 45 % de départs, il doit faire l'objet d'une priorité de rétention, au moyen d'une offre famille, d'un interlocuteur dédié et de relances avant résiliation.

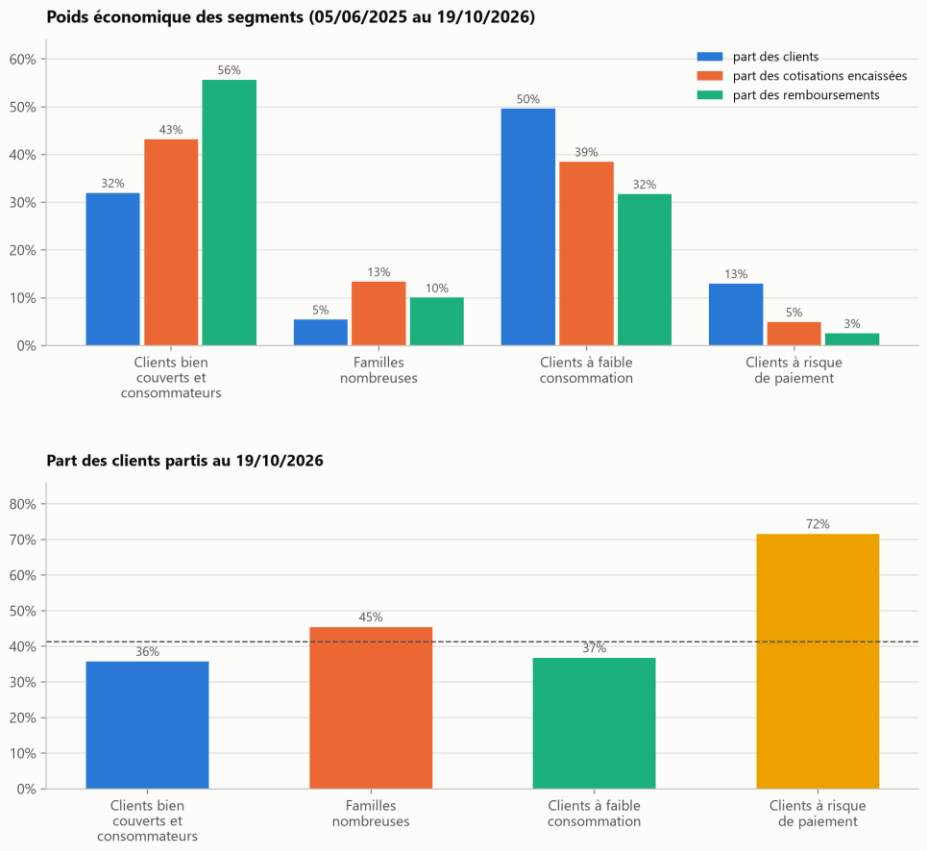
Faible consommation

Ce segment rassemble la moitié des clients et consomme environ 11 € par mois. Le risque est une résiliation faute de perception de valeur. Les actions proposées sont de rendre visibles les garanties, les remboursements et une montée en gamme ciblée.

Risque de paiement

Ce segment représente 13 % des clients, avec environ 63 % de prélèvements échoués et 72 % de départs. Il s'agit d'une fuite à l'entrée. Les actions proposées sont la sécurisation des prélèvements, les relances et l'accompagnement jusqu'au premier remboursement.

Figure 17 : Poids économiques des segments



Interprétation

Le segment bien couvert et consommateur représente 56 % des remboursements, tandis que le segment à risque de paiement concentre 72 % de departs.

Les profils démographiques, contractuels et professionnels complètent l'interprétation des quatre segments.

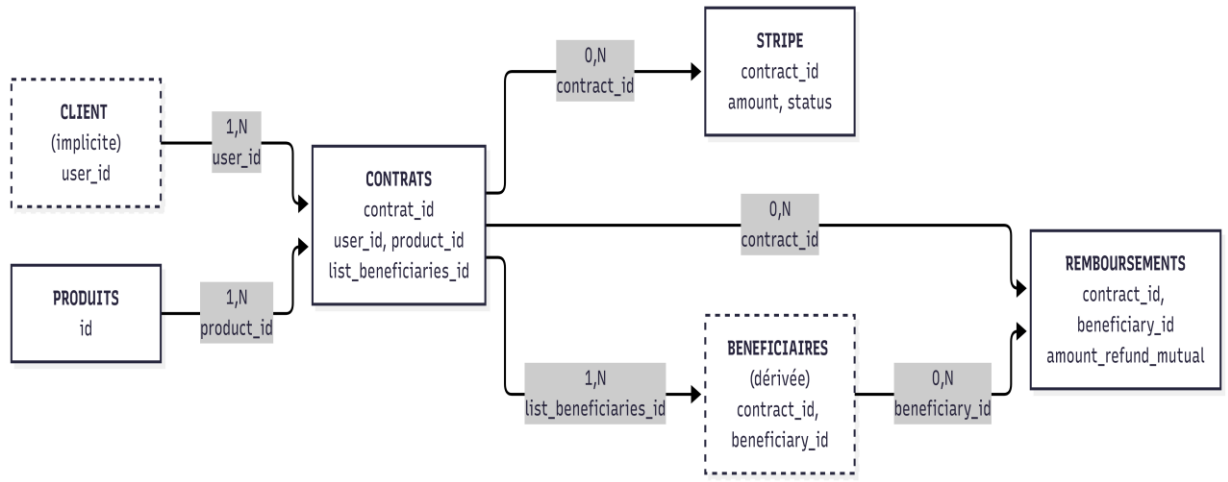
La segmentation met en évidence quatre profils aux enjeux économiques distincts. Les clients bien couverts et consommateurs, qui représentent 32 % du portefeuille, génèrent 43 % des cotisations mais concentrent 56 % des remboursements, ce qui en fait le segment le plus sensible à la sinistralité et nécessite une fidélisation adaptée. Les familles nombreuses, bien que limitées à 5 % des clients, contribuent à 13 % des cotisations, mais affichent un taux de départ particulièrement élevé de 45 % ; leur rétention constitue donc un enjeu prioritaire. À l'inverse, le segment faible consommation, qui rassemble la moitié des clients et 39 % des cotisations, ne représente que 32 % des remboursements. Il offre un potentiel de rentabilité, à condition de renforcer la perception de la valeur des garanties et des services pour limiter les résiliations. Enfin, le segment risque de paiement illustre une fragilité dès l'entrée dans le portefeuille : ces clients récents cumulent 63 % d'échecs de prélèvement et 72 % de départs, ce qui souligne l'importance de sécuriser les paiements et d'accompagner les adhérents durant leurs premiers mois. Au global, avec un S/P apparent de 29 % et 41 % de clients partis, les données invitent à protéger les segments à forte contribution, réduire les départs précoces liés aux difficultés de paiement et renforcer la valeur perçue auprès des clients peu consommateurs.

Partie 4 : Data Engineering (question bonus)

Question 1 : Modèle de données et diagramme des relations

Le modèle source contient implicitement les entités Client et Bénéficiaire. La liste des bénéficiaires présente dans les contrats est dépliée dans une table pont.

Figure 19 : Relations entre les tables sources



Interprétation

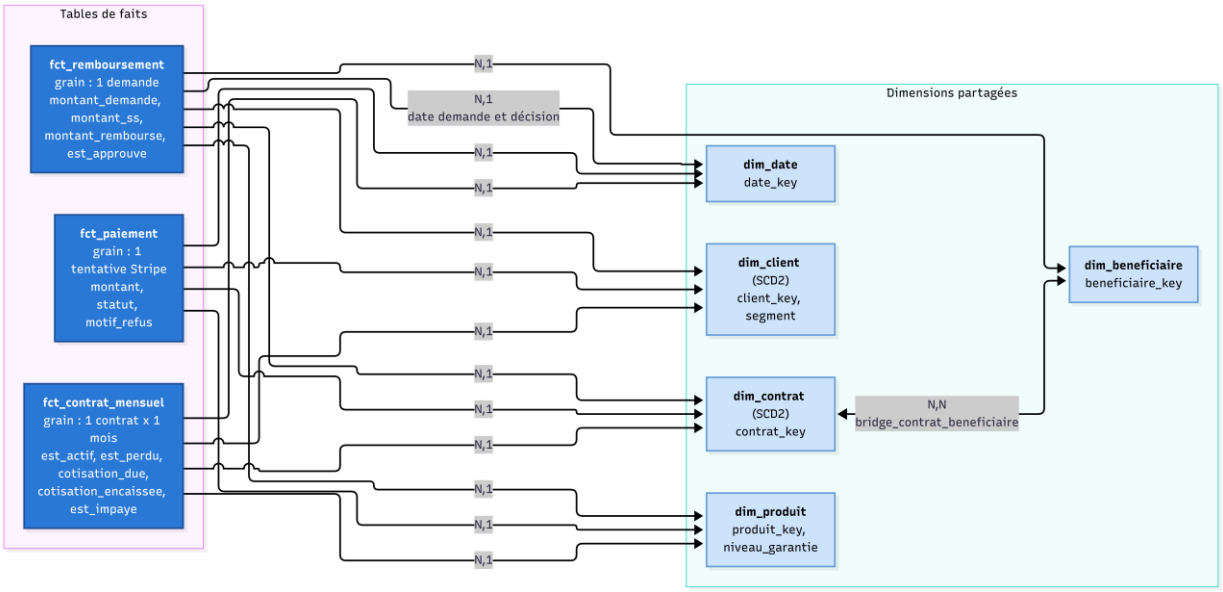
Le modèle source relie les contrats aux produits, clients, paiements, remboursements et bénéficiaires.

Relation	Clé	Cardinalité
Produit → Contrat	product_id	1 produit, N contrats
Client → Contrats	user_id	1 client, N contrats
Contrat → Stripe	contract_id	1 contrat, 0 à N paiements
Contrat → Remboursements	contract_id	1 contrat, 0 à N demandes
Contrat ↔ Bénéficiaires	liste de bénéficiaires	relation plusieurs-à-plusieurs
Bénéficiaire → Remboursements	beneficiary_id	1 bénéficiaire, 0 à N demandes

Question 2 : Construction du data warehouse

Le modèle cible est dimensionnel. Les faits enregistrent les événements mesurables et les dimensions fournissent le contexte d'analyse.

Figure 20 : Modèle dimensionnel cible



Interprétation

Le modèle cible sépare les faits mesurables des dimensions partagées et gère la relation plusieurs-à-plusieurs entre contrats et bénéficiaires.

Table	Grain ou rôle
fct_paiement	Une tentative Stripe
fct_remboursement	Une demande de remboursement
fct_contrat_mensuel	Un contrat par mois
dim_date	Dimension de dates
dim_client	Client, historisé en SCD2
dim_contrat	Contrat, historisé en SCD2
dim_produit	Référentiel produit
dim_beneficiaire	Bénéficiaire
bridge_contrat_beneficiaire	Relation N-N

5.3 Construction proposée

Cadrage

Définir les indicateurs métier, leur grain, les règles de client gagné et perdu et les contraintes RGPD/HDS.

Ingestion

Mettre en place des extractions incrémentales, récupérer les identifiants Stripe et les dates de dépôt et de virement des remboursements.

Bronze

Conserver une copie fidèle, horodatée et rejouable des sources.

Silver

Typer, dédoublonner, normaliser, déplier les bénéficiaires, calculer les flags et mettre les lignes corrompues en quarantaine.

Gold

Construire les dimensions, les faits, la photo mensuelle et les agrégats métier.

Qualité

Convertir les anomalies de la partie 1 en tests automatiques bloquants ou en avertissements.

Orchestration

Exécuter quotidiennement les extractions, transformations, tests et rafraîchissements.

Exposition

Publier les indicateurs dans les tableaux de bord et restituer les segments au CRM.

Gouvernance

Pseudonymiser, gérer les rôles, documenter le lignage et appliquer les durées de conservation.

Étape	Outil principal	Alternative
Ingestion	Airbyte, API Stripe, Debezium	Fivetran, Python
Stockage brut	Parquet et stockage objet HDS	Schéma raw SQL
Transformation	dbt SQL	PySpark si le volume augmente
Entrepôt	PostgreSQL managé	BigQuery ou Snowflake
Qualité	Tests dbt et SQL	Great Expectations ou Soda
Orchestration	Airflow	Dagster ou Prefect
Restitution	Metabase	Power BI
Gouvernance	dbt docs et RBAC	DataHub ou OpenMetadata

5.4 Prototype et réconciliation

Le notebook construit un prototype SQLite d'environ 95 Mo à partir des tables nettoyées. Les tests bloquants passent et les avertissements retrouvent les anomalies de la partie 1.

Le S/P apparent calculé en SQL sur la couche gold est de 28,9 %, avec un écart maximal de $5{,}6 \times 10^{-17}$ par rapport au calcul pandas. Cette réconciliation confirme la cohérence des jointures, des agrégations et du modèle cible.

Le notebook indique également que le segment à risque de paiement présente un taux d'impayé mensuel de 17,1 %, contre 1,5 % à 3,5 % pour les autres segments. Le segment des clients bien couverts et consommateurs possède le S/P le plus élevé, à 36 % dans la requête SQL par segment.

Plan de mise en œuvre du data warehouse

Phase	Contenu	Résultat
1. Socle	Ingestion quotidienne des quatre sources, couches bronze et silver, tests bloquants	Données propres chaque matin et fin des exports manuels
2. Modèle métier	Couche gold avec faits, dimensions, photo mensuelle et tableaux de bord	Indicateurs définis une seule fois et partagés
3. Historisation et qualité	CDC, SCD2 et alertes métier vers la finance et la gestion	Historique fiable et anomalies traitées à la source
4. Usages avancés	Segmentation mensuelle, score de risque de départ et retour vers le CRM	Actions marketing ciblées et mesurées

En résumé, la valeur vient principalement de trois décisions : des définitions métier écrites une seule fois dans la couche gold, des tests qui transforment chaque anomalie connue en alerte automatique et une ingestion directe depuis les sources, qui supprime à la racine les problèmes de format. Les outils sont importants, mais ces trois décisions structurent la réussite du dispositif.

6. Limites et recommandations

- Le délai réel de remboursement n'est pas mesurable avec les dates disponibles.
- Les sources d'acquisition sont manquantes pour 80,3 % des contrats.
- Les dates de création et de signature sont affectées par la migration et les dates par défaut.
- Les motifs de perte sont déduits de l'historique et doivent être rapprochés d'un statut métier officiel.
- Les données de remboursement doivent faire l'objet d'une gouvernance renforcée compte tenu de leur caractère sensible.

La priorité est d'industrialiser l'ingestion, les tests de qualité et la photo mensuelle, tout en traitant les impayés, les paiements après clôture, les remboursements sans cotisation et les départs précoces.

Annexe : Organisation du dossier

- notebooks/01_data_quality.ipynb
- notebooks/02_statistiques.ipynb
- notebooks/03_segmentation_clients.ipynb
- notebooks/04_data_engineering.ipynb
- data/processed/
- data/warehouse/nostrumcare_dwh.sqlite
- figures/
- rapport/Rapport_Test_Technique_NostrumCare.pdf